

DOSSIER MCP

Chess Agent / AgentIA

Étude de faisabilité complète, architecture, contrats, risques, budget, qualité et plan de preuve

GO CONDITIONNEL : coeur échiquéen et MCP faisables ; vision vidéo limitée à un corpus autorisé et contrôlé.

Périmètre consolidé à partir des discussions antérieures et des onze fichiers fournis.

Version 1.0 - 18 août 2026

Sommaire

- 1** Synthèse exécutive
- 2** Étude de faisabilité complète
- 3** Exigences et traçabilité
- 4** Architecture MCP
- 5** Pipeline vidéo vers position et timestamp
- 6** Sécurité et conformité
- 7** Qualité, tests et recette
- 8** Plan, charges et budget
- 9** Registre des risques et alternatives
- 10** Décisions, hypothèses et questions
- 11** Audit des fichiers fournis
- 12** Soutenance et dossier de preuves
- 13** Inventaire des sources

Les contrats YAML/JSON, diagrammes Mermaid, fichiers Python d'origine et matrice CSV sont fournis dans l'archive du dossier.

Synthèse exécutive

Objet

Concevoir un assistant pédagogique d'ouvertures d'échecs qui reçoit une position FEN, identifie l'ouverture, propose des coups issus de la théorie ou de Stockfish, enrichit la réponse par RAG et retrouve une vidéo pertinente à un timestamp précis. Les capacités sont exposées à un agent IA via MCP et à une interface Angular via FastAPI.

Verdict

Go conditionnel pour un POC puis un MVP sur corpus contrôlé.

- Go : validation FEN, identification ECO, statistiques/théorie Lichess, repli Stockfish, RAG Milvus, persistance MongoDB, API FastAPI, interface Angular et serveur MCP.
- Go sous expérimentation : détection de l'échiquier et des pièces dans des vidéos hétérogènes, reconstruction temporelle de la position et précision du timestamp.
- No-Go en l'état : téléchargement et stockage automatisés de vidéos YouTube tierces sans autorisation. Le système doit indexer des vidéos détenues/licenciées ou téléversées par un utilisateur autorisé ; pour YouTube, il conserve de préférence identifiant, métadonnées, positions dérivées autorisées et lien horodaté.

Score de faisabilité

Dimension	Poids	Note / 5	Commentaire
Coeur échiquéen et API	25 %	4,5	Bibliothèques et services matures ; intégration à réaliser.
MCP et agent orchestration	15 %	4,0	SDK Python v2 stable ; protocole 2026-07-28 sans session.
RAG et données	15 %	3,5	Faisable, sous réserve de corpus et d'évaluation de pertinence.
Vision vidéo -> position	20 %	2,8	Faisable sur corpus contrôlé ; généralisation non prouvée.
Sécurité, conformité, droits	15 %	2,5	Bloquant tant que les droits vidéo et la base RGPD ne sont pas cadrés.
Exploitation et coûts	10 %	3,5	Coûts maîtrisables avec traitement batch et quotas.
Total pondéré	100 %	3,5 / 5	Faisable sous conditions et par paliers.

Périmètre recommandé

POC démontrable

- entrée FEN validée ;
- identification d'ouverture et variante ;
- coups Lichess puis Stockfish si la théorie est absente ;
- recupération RAG sur un petit corpus ;
- recherche dans 20 à 50 vidéos autorisées pré-indexées ;
- six outils MCP principaux ;
- interface Angular minimale ;
- mesures de qualité et preuves reproductibles.

MVP

- gestion de comptes et préférences ;
- pipeline asynchrone d'indexation vidéo ;

- observabilité, contrôle d'accès et reprise sur erreur ;
- corpus élargi et jeu de vérité terrain ;
- critères de qualité bloquants ;
- déploiement Streamable HTTP sécurisé.

Ordres de grandeur

Hypothèses : équipe mixte, tarifs moyens de 550 à 750 EUR par jour, hors taxes, hors achat de données et hors marge contractuelle.

Niveau	Charge	Délai calendaire	Investissement estimatif
Démonstrateur POC	45 à 65 j.h	8 à 12 semaines	30 kEUR à 45 kEUR
MVP corpus contrôlé	115 à 165 j.h	4 à 6 mois	75 kEUR à 115 kEUR
Bêta production	210 à 310 j.h	7 à 10 mois	145 kEUR à 220 kEUR

OPEX mensuel indicatif : 50 à 250 EUR pour une démonstration locale/cloud légère, 350 à 1 800 EUR pour un MVP, 2 000 à 7 500 EUR pour une petite production. La vision GPU, le volume vidéo et les appels LLM sont les principaux facteurs de variation.

Conditions de Go

- 1 Les vidéos du pilote sont détenues, téléversées avec autorisation ou couvertes par une licence exploitable.
- 2 Un jeu de vérité terrain d'au moins 1 000 frames et 200 séquences est annoté.
- 3 Le POC atteint au minimum 90 % de positions de pièces exactes sur le corpus contrôlé et une erreur de timestamp P90 inférieure ou égale à 2 secondes.
- 4 Les appels Lichess respectent la sérialisation et le délai après HTTP 429.
- 5 Les secrets, journaux, comptes et données personnelles sont cadrés.
- 6 Le serveur MCP passe les tests de contrats, d'autorisation et de non-régression.

Décision proposée

Lancer un lot de réduction des risques de trois semaines avant le MVP : droits vidéo, benchmark vision, validation du catalogue MCP et mesure des quotas. À son issue, le comité décide de poursuivre le pipeline vidéo, de le limiter aux vidéos maîtrisées ou de conserver uniquement la recommandation par métadonnées.

Étude de faisabilité complète

1. Cadre de l'étude

1.1 Besoin consolidé

Le projet Chess Agent / AgentIA vise un assistant pédagogique capable de :

- 1 recevoir une position d'échecs au format FEN ;
- 2 reconnaître une ouverture et sa variante ;
- 3 interroger Lichess pour la théorie et les statistiques ;
- 4 utiliser Stockfish lorsque la position n'est pas couverte par la théorie ;
- 5 enrichir l'analyse avec des documents retrouvés dans Milvus ;
- 6 recommander des vidéos YouTube ;
- 7 retrouver, dans des vidéos indexées, le passage où apparaît une position et fournir un lien horodaté ;
- 8 orchestrer le parcours avec LangGraph ;
- 9 exposer les capacités par FastAPI, MCP et une interface Angular/ngx-chessboard ;
- 10 conserver les données métier et l'historique utile dans MongoDB.

La mission est une conception prouvable, pas la prétention que tous ces éléments sont déjà développés. Les onze fichiers fournis constituent une base de contrats Pydantic et une convention MISA, mais pas un produit exécutable.

1.2 Sources analysées

- Convention MISA v2.0.
- Schémas : evaluation, user, document, analysis, video, move, error, opening, position, enums.
- Discussions antérieures : stack imposée, workflow FEN -> Lichess -> Stockfish -> RAG -> YouTube, pipeline vidéo et obligation de couverture exhaustive.
- Références officielles listées dans 12-inventaire-sources.md.

1.3 Méthode

L'étude sépare :

- les exigences mission, qui décrivent le résultat attendu ;
- les choix d'ingénierie, qui peuvent évoluer sans changer la mission ;
- les preuves existantes, limitées aux fichiers réellement reçus ;
- les hypothèses de chiffrage, à confirmer pendant le cadrage.

2. Faisabilité fonctionnelle

2.1 Parcours principal

Le parcours nominal est cohérent :

- 1 l'utilisateur saisit ou construit une FEN ;
- 2 le backend la valide avec python-chess ;
- 3 le système normalise la position et calcule une clé stable ;
- 4 une base d'ouvertures/ECO tente l'identification ;
- 5 Lichess fournit coups et statistiques lorsque disponibles ;

- 6 Stockfish prend le relais selon une limite de temps déterministe ;
- 7 Milvus retrouve explications et documents ;
- 8 l'agent compose une réponse pédagogique avec traçabilité des sources ;
- 9 l'index vidéo recherche la position ou ses positions voisines ;
- 10 l'API renvoie l'analyse, les recommandations et les liens horodatés.

Ce parcours est fonctionnellement réalisable. Le principal point d'incertitude est la qualité du passage vidéo -> position, non le traitement échiquéen.

2.2 Utilisateurs cibles

À valider avec le commanditaire :

- joueurs débutants et intermédiaires apprenant des ouvertures ;
- entraîneurs préparant des supports ;
- clubs ou plateformes pédagogiques ;
- utilisateurs d'un agent IA compatible MCP.

Le modèle UserPreferences montre déjà une personnalisation par couleur, ouvertures, difficulté et langue. L'usage de comptes crée toutefois des obligations RGPD absentes des fichiers transmis.

2.3 Hors périmètre initial recommandé

- analyse temps réel d'un flux live ;
- indexation sans autorisation de l'ensemble de YouTube ;
- garantie de FEN complète depuis une image isolée ;
- jeu automatisé sur une plateforme ;
- entraînement d'un modèle de vision généraliste sur tout style d'échiquier ;
- conseil échiquéen compétitif sans indication d'incertitude.

3. Faisabilité technique

3.1 Compatibilité de la stack

Composant	Rôle	Avis
FastAPI	API interne, health checks, surface HTTP	Adapté aux schémas Pydantic existants.
LangGraph	Orchestration des étapes et replis	Adapté, mais l'état doit rester métier et testable.
MongoDB	utilisateurs, jobs, métadonnées, résultats	Adapté ; indexation et rétention à définir.
Milvus	recherche vectorielle	Adapté au RAG ; surdimensionné si le corpus reste très petit.
Stockfish	analyse hors théorie	Très adapté ; encadrer temps, profondeur et concurrence.
Lichess API	théorie/statistiques	Adapté sous respect strict du rate limiting.
YouTube Data API	découverte et métadonnées	Adapté ; ne fournit pas un droit général de télécharger les vidéos.
Angular/ngx-chessboard	interface interactive	Adapté ; vérifier compatibilité de version au démarrage.
MCP Python SDK v2	exposition à des hôtes IA	Adapté à Python et au protocole 2026-07-28.
Docker Compose	environnement local/POC	Adapté ; la production demandera orchestration, sauvegardes et secrets.

3.2 Architecture MCP

Le protocole MCP 2026-07-28 est sans session au niveau protocolaire. Chaque requête doit être autonome. Les traitements longs utilisent donc un job_id explicite, enregistré dans MongoDB, plutôt qu'un état caché dans la

connexion.

Le serveur expose :

- des tools pour valider/analyser/rechercher ;
- des ressources pour lire les ouvertures, positions et timelines ;
- des prompts pour structurer les explications pédagogiques ;
- le transport stdio en local et Streamable HTTP en environnement distant.

Le catalogue détaillé est dans `02_contrats/mcp-catalogue.yaml`. Pour éviter une dépendance prématurée à l'extension MCP Tasks, le MVP utilise `video.start_indexing` puis `video.get_indexing_status`. Cette décision pourra être revue lorsque l'extension et son support SDK seront validés par tests de conformité.

3.3 Faisabilité du pipeline vidéo

Entrée autorisée

Le pipeline accepte :

- un fichier détenu par l'organisation ;
- un fichier téléversé par un utilisateur attestant disposer des droits ;
- un flux ou objet fourni contractuellement par un créateur ;
- un corpus open data dont la licence autorise le traitement.

Il n'est pas recommandé de télécharger automatiquement des contenus YouTube tiers. Pour une vidéo YouTube, la couche de recommandation utilise l'API officielle et le lecteur intégré ; l'analyse des octets exige une autorisation distincte.

Étapes

- 1 Ingestion et empreinte du fichier.
- 2 Échantillonnage adaptatif des frames.
- 3 Détection de la zone d'échiquier.
- 4 Rectification de perspective et orientation.
- 5 Classification des 64 cases.
- 6 Lissage temporel entre frames.
- 7 Validation de légalité avec `python-chess`.
- 8 Reconstruction de la séquence de coups si l'état initial est connu.
- 9 Production d'une position normalisée avec score de confiance.
- 10 Indexation de la position, de la plage temporelle et de la source.

Limite FEN fondamentale

Une image isolée révèle principalement la disposition des pièces. Elle ne permet généralement pas de déduire avec certitude :

- le joueur au trait ;
- les droits de roque ;
- la case de prise en passant ;
- les compteurs de demi-coups et de coups.

La sortie de vision doit donc distinguer `piece_placement` de `full_fen`. Une FEN complète n'est déclarée que si la séquence antérieure ou une métadonnée fiable permet de reconstruire les champs manquants. Sinon, le résultat porte un état `partial` et des valeurs inconnues explicites.

3.4 Performance

Objectifs initiaux à confirmer :

Opération	Objectif P95
Validation FEN	100 ms
Identification ouverture locale	300 ms
Réponse théorie avec cache	2 s
Analyse Stockfish	3 à 8 s selon budget moteur
Recherche RAG	1,5 s
Recherche position vidéo pré-indexée	1 s
Démarrage d'un job vidéo	500 ms, traitement asynchrone

La latence globale doit être bornée par étape. LangGraph ne doit pas masquer les timeouts ni lancer des appels externes non bornés.

3.5 Données et modèles

MongoDB conserve les objets transactionnels : utilisateurs, préférences, jobs, vidéos, timelines, analyses et erreurs. Milvus conserve les embeddings de documents et éventuellement des représentations de positions. Les positions exactes doivent d'abord être recherchées par clé déterministe ; le vectoriel sert à la proximité sémantique ou positionnelle, pas à remplacer une égalité exacte.

Une clé de position peut reposer sur :

- FEN normalisée pour une position complète ;
- placement des pièces + trait lorsque disponible ;
- hachage stable documenté ;
- version du détecteur et niveau de confiance.

4. Faisabilité opérationnelle

4.1 Déploiement

Le POC peut fonctionner avec Docker Compose. Le MVP distant sépare au minimum :

- API/MCP stateless ;
- workers Stockfish ;
- workers vidéo CPU/GPU ;
- MongoDB ;
- Milvus ou service managé ;
- stockage objet ;
- file de travaux ;
- collecte de logs, métriques et traces.

Les workers vidéo sont extensibles horizontalement. Les appels Lichess sont sérialisés par une passerelle avec cache et backoff. Les liens YouTube sont calculés à partir d'un timestamp stocké, sans répliquer la vidéo.

4.2 Exploitabilité

Chaque analyse reçoit un request_id; chaque ingestion un job_id. Les appels sont idempotents. Les traces contiennent les durées, statuts et versions de modèles, jamais les secrets ni le contenu personnel inutile.

SLO MVP proposés : disponibilité 99,5 %, taux d'erreur interne inférieur à 1 %, reprise d'un job interrompu sans doublon, sauvegarde quotidienne des métadonnées et RPO de 24 h.

4.3 Dépendances externes

- Lichess demande un seul appel simultané et une pause complète d'une minute après HTTP 429.
- YouTube applique des quotas et peut exiger un audit pour une extension.
- Les SDK, modèles de vision et bibliothèques doivent être verrouillés et scannés.
- Une indisponibilité externe ne doit pas empêcher une réponse dégradée locale.

5. Faisabilité juridique et conformité

5.1 Vidéos

Le stockage et l'analyse d'une vidéo sont distincts du droit d'afficher un lecteur YouTube. Les conditions YouTube restreignent notamment le téléchargement et l'usage automatisé non autorisé. Le MVP doit donc conserver une preuve de provenance/licence pour chaque fichier analysé.

Décision d'architecture :

- vidéo autorisée : stockage objet chiffré, durée de rétention définie ;
- vidéo YouTube tierce non autorisée : métadonnées API, identifiant, miniature permise, positions provenant seulement d'une source autorisée, lien <https://www.youtube.com/watch?v=...&t=...s> ;
- retrait source : désindexation et purge traçable.

5.2 Données personnelles

Les modèles User, UserProfile et UserPreferences impliquent identifiant, pseudo, email et préférences. Avant production : registre de traitement, finalités, base légale, minimisation, durée de conservation, droits d'accès/effacement, export, sécurité et contrats de sous-traitance.

5.3 Propriété intellectuelle et modèles

Chaque document RAG doit stocker source, URL, auteur, date, licence et règle de citation. Les réponses générées doivent indiquer les sources utilisées et éviter de reproduire de longs passages protégés.

6. Faisabilité économique

6.1 Investissement

Trois niveaux sont proposés :

Niveau	Contenu	Charge	Coût estimatif
POC	coeur FEN, MCP, petit RAG, 20-50 vidéos contrôlées, UI minimale	45-65 j.h	30-45 kEUR
MVP	comptes, pipeline asynchrone, sécurité, corpus annoté, CI/CD	115-165 j.h	75-115 kEUR
Bêta production	haute disponibilité, observabilité, corpus élargi, conformité	210-310 j.h	145-220 kEUR

Les montants reposent sur 550 à 750 EUR/jour. Ils excluent licences de contenus, acquisition de données, audit juridique externe, support 24/7 et TVA.

6.2 OPEX mensuel

Poste	Démo	MVP	Petite production
API et workers CPU	0-50 EUR	80-350 EUR	600-2 000 EUR
MongoDB	0-30 EUR	30-150 EUR	100-600 EUR
Milvus/Zilliz	0-50 EUR	50-350 EUR	200-1 200 EUR
Stockage et trafic	0-20 EUR	20-150 EUR	100-800 EUR
GPU vidéo batch	0-80 EUR	100-600 EUR	500-2 500 EUR
LLM/embeddings	0-50 EUR	50-500 EUR	300-2 000 EUR

Poste	Démo	MVP	Petite production
Logs, sauvegardes, sécurité	0-20 EUR	20-200 EUR	200-800 EUR
Total	0-250 EUR	350-1 800 EUR	2 000-7 500 EUR

Le stockage des frames est à éviter : conserver la vidéo autorisée, les timestamps, crops de preuve limités et artefacts nécessaires. La suppression des frames intermédiaires réduit fortement le coût et le risque.

6.3 Valeur attendue

- accès direct au bon passage pédagogique ;
- réduction du temps de recherche d'une explication ;
- parcours personnalisé ;
- réutilisation des mêmes capacités dans plusieurs hôtes grâce à MCP ;
- corpus et métriques capitalisables.

Le modèle économique n'a pas été décidé. Options à évaluer ultérieurement : outil interne de club/formation, abonnement B2C, licence B2B pour entraîneurs ou API. Aucun revenu n'est intégré au verdict de faisabilité.

7. Qualité et preuves

7.1 Seuils POC

- 100 % des FEN invalides du jeu de test sont rejetées proprement ;
- 100 % des coups proposés sont légaux dans la position ;
- aucun appel Lichess concurrent ;
- récupération après 429 conforme au délai ;
- exactitude du placement des pièces ≥ 90 % sur le corpus contrôlé ;
- rappel de détection d'échiquier ≥ 95 % ;
- erreur de timestamp P90 ≤ 2 s ;
- Recall@5 RAG $\geq 0,80$ sur les questions annotées ;
- aucun secret dans le dépôt ou les logs ;
- contrats MCP et OpenAPI validés automatiquement.

7.2 Preuve soutenable

Pour chaque exigence, conserver : cas de test, entrée, résultat attendu, résultat réel, version de code/modèle, journal horodaté et capture ou rapport. La matrice 02-exigences-et-tracabilite.md est la source de vérité de la couverture.

8. Risques déterminants

- 1 Droits vidéo : peut interdire le scénario d'ingestion choisi.
- 2 FEN impossible depuis une frame seule : nécessite reconstruction temporelle et statut partiel.
- 3 Variabilité visuelle : échiquiers 2D/3D, overlays, transitions, caméra, compression.
- 4 Quotas externes : Lichess/YouTube imposent cache, limitation et modes dégradés.
- 5 Contrats incomplets : timestamp, job, confiance et provenance absents des schémas actuels.
- 6 Coût GPU/LLM : dérive si les vidéos sont retraitées ou si le cache est insuffisant.
- 7 Explications non fiables : le LLM doit décrire des sorties structurées et sourcées, pas inventer des variantes.

9. Alternatives

A. Métadonnées seulement

Recherche vidéo par titre, description et chapitres, sans analyser les images. Coût et risque faibles, précision positionnelle faible. Adapté comme repli légal.

B. Corpus éditorialisé

Créateurs partenaires fournissant vidéos et PGN/timelines. Meilleure qualité et conformité. Recommandation prioritaire pour le MVP.

C. Vision contrôlée

Analyse limitée à un ou deux layouts d'échiquier. Bon compromis pour prouver la chaîne technique.

D. Vision généraliste

Tout type de vidéo et de perspective. Coût élevé, besoin de données important, non recommandé avant preuve du MVP.

10. Plan de mise en oeuvre

Phase 0 - Réduction des risques, 3 semaines

- définir les droits et le corpus ;
- annoter un échantillon ;
- benchmarker deux approches de vision ;
- figer les contrats MCP et vidéo ;
- établir les budgets de temps Stockfish, quotas et cache.

Phase 1 - Coeur déterministe, 3 à 4 semaines

- validation FEN ;
- ouverture/ECO ;
- Lichess et Stockfish ;
- API, erreurs, idempotence ;
- tests et métriques.

Phase 2 - RAG et MCP, 3 à 4 semaines

- ingestion documentée ;
- recherche Milvus ;
- outils/ressources/prompts MCP ;
- auth locale/distance ;
- conformité protocolaire.

Phase 3 - Vidéo contrôlée, 5 à 8 semaines

- ingestion autorisée ;
- détection et reconstruction ;
- timeline indexée ;
- recherche FEN -> timestamp ;

- évaluation sur vérité terrain.

Phase 4 - Frontend, durcissement et pilote, 4 à 6 semaines

- expérience Angular ;
- comptes/préférences ;
- observabilité, sauvegarde, sécurité ;
- recette et pilote utilisateurs.

11. Critères Go/No-Go

Porte	Go	No-Go / pivot
Juridique	droits documentés pour tout fichier analysé	provenance ou licence absente
Vision	>= 90 % de placements exacts sur corpus cible	< 80 % après deux itérations
Timestamp	P90 <= 2 s	P90 > 5 s
Coût	coût/heure vidéo compatible avec budget	retraitements GPU non maîtrisés
MCP	catalogue stable, auth et contrats validés	dépendance à état de session caché
Pédagogie	réponses légales, sourcées, utiles	hallucinations de coups ou sources

Entre les seuils Go et No-Go, une itération corrective time-boxée est autorisée. Le pivot privilégié est un corpus éditorialisé avec PGN/timelines fournis.

12. Conclusion

Le projet est techniquement cohérent et présente une valeur pédagogique claire. Sa réussite dépend d'une stratégie par paliers : coeur échiquéen déterministe, MCP standardisé, RAG mesuré, puis vision sur corpus légalement et visuellement contrôlé. Le dossier recommande un Go conditionnel, précédé d'un lot court de réduction des risques et suivi de portes de décision quantitatives.

Exigences et traçabilité

Règle de preuve

Une exigence n'est considérée couverte que si les six colonnes sont renseignées : phase, fichier cible, méthode, test, preuve et statut. Les preuves indiquées ci-dessous sont attendues sauf lorsque le statut mentionne explicitement un élément déjà présent.

A. Exigences mission

ID	Exigence	Phase	Fichiers/composants cibles	Méthode	Test/vérification	Preuve soutenable	Statut
MIS-01	Stocker les vidéos à analyser	0, 3	ingestion, stockage objet, VideoAsset	n'accepter que fichiers autorisés, hash et provenance	upload, doublon, retrait, rétention	métadonnées + preuve de licence + journal de purge	À concevoir
MIS-02	Extraire les frames	3	worker vidéo	échantillonnage adaptatif et keyframes	vidéo courte/longue, cadence variable	rapport nombre de frames et durées	À concevoir
MIS-03	Détecter l'échiquier	3	modèle CV	détection, coins, rectification	corpus annoté multi-layout	précision/rappel par version de modèle	À expérimenter
MIS-04	Détecter les pièces	3	classifieur 64 cases	classification + confiance	matrice de confusion par pièce/case	rapport métriques + exemples d'échec	À expérimenter
MIS-05	Convertir en position/FEN	3	reconstructeur temporel	légalité + suivi séquentiel	séquences avec coups, roque, promotion	taux placement exact et FEN complète	Contrat manquant
MIS-06	Gérer l'incertitude FEN	3	schémas vidéo	partial/complete, champs inconnus	image isolée sans historique	réponse explicite sans FEN inventée	Recommandé
MIS-07	Indexer position et timestamp	3	MongoDB/index exact	segments temporels et clé de position	même position répétée, plans coupés	requête DB + timeline attendue	Contrat manquant
MIS-08	Rechercher une vidéo par FEN	3	service recherche, MCP	exact puis proximité contrôlée	FEN présente, absente, partielle	résultat classé avec confiance	À concevoir
MIS-09	Retourner un lien YouTube horodaté	3	service lien	identifiant + seconde de début	URL, arrondi et offset	ouverture au passage attendu	Contrat manquant
MIS-10	Fournir bénéfices et limites	Documentation	étude	analyse multicritère	revue par commanditaire	sections 2, 8 et 9 de l'étude	Couvert dossier
MIS-11	Fournir architecture MCP	2	doc architecture, diagrammes	tools/resources/prompts, transports	revue + validation catalogue	diagrammes et YAML	Couvert conception
MIS-12	Chiffrer build et OPEX	0, 4	plan budget	charges bottom-up et scénarios	revue hypothèses	tableau charges + sensibilités	Couvert estimation
MIS-13	Décrire risques et alternatives	Toutes	registre risques	probabilité, impact, mitigation	revue portes Go/No-Go	registre versionné	Couvert dossier
MIS-14	Décrire les étapes	Toutes	roadmap	phases, dépendances, livrables	jalons d'acceptation	planning et checklist	Couvert dossier

B. Exigences produit

ID	Exigence	Phase	Fichiers/composants cibles	Méthode	Test/vérification	Preuve soutenable	Statut
APP-01	Recevoir une FEN	1	AnalysisRequest, FenRequest	modèle unique + normalisation	FEN valide/invalid/espaces	tests Pydantic + python-chess	Partiel existant
APP-02	Identifier ouverture/variante ECO	1	service opening, OpeningDetails	base ECO et transpositions	corpus positions connues	taux d'identification	Schémas présents
APP-03	Proposer théorie Lichess	1	client Lichess	cache, sérialisation, timeout	réponses vide/429/5xx	tests mock + métriques	À développer
APP-04	Repli Stockfish	1	worker moteur	temps maximal et MultiPV	théorie absente, moteur indisponible	ligne légale + temps borné	Schémas présents
APP-05	Enrichir par RAG Milvus	2	ingestion/retrieval	chunks sourcés, seuil de similarité	jeu de questions annoté	Recall@5/NDCG + citations	Schémas présents
APP-06	Recommander des vidéos	2, 3	service YouTube, VideoCollection	requête, cache, pertinence	quota, aucun résultat	raison + score + source	Schémas partiels

ID	Exigence	Phase	Fichiers/composants cibles	Méthode	Test/vérification	Preuve soutenable	Statut
APP-07	Générer explication pédagogique	2	agent/LangGraph	LLM contraint par données structurées	coup illégal, source absente	validation de légalité et citation	À développer
APP-08	Interface échiquier Angular	4	Angular/ngx-chessboard	saisie FEN et affichage variantes	E2E clavier/mobile/erreurs	vidéo de recette + tests	À développer
APP-09	Gérer préférences utilisateur	4	UserProfile	langue, difficulté, ouvertures	lecture/édition/effacement	tests API + audit RGPD	Schémas présents
APP-10	Réponse dégradée	1, 2	LangGraph, erreurs	repli par dépendance	LLM/Mongo/Milvus/API indisponibles	réponse partielle typée	À concevoir
APP-11	Idempotence	1, 3	analyses/jobs MongoDB	request_id, job_id, index unique	répétition/reprise	un seul résultat logique	Absent fichiers reçus

C. Choix d'ingénierie

Ces éléments ne sont pas des exigences métier immuables ; ils sont retenus par les discussions et doivent être revalidés si une contrainte change.

ID	Choix	Phase	Fichier/composant	Justification	Test	Preuve	Statut
ENG-01	FastAPI	1	API	cohérence Pydantic/Python	OpenAPI et tests contrat	schéma généré	Décidé
ENG-02	LangGraph	1, 2	orchestration	replis et étapes explicites	transitions, reprise, timeouts	traces de graphe	Décidé
ENG-03	MongoDB	1	persistance	documents et jobs	index, reprise, sauvegarde	plan de restauration	Décidé
ENG-04	Milvus	2	vector store	RAG et montée en charge	qualité/latence	benchmark	Décidé
ENG-05	Stockfish	1	moteur UCI	référence déterministe	légalité, timebox	rapport moteur	Décidé
ENG-06	Angular/ngx-chessboard	4	frontend	échiquier interactif	test compatibilité versions	build reproductible	Décidé
ENG-07	Docker Compose	1	dev/POC	environnement reproductible	démarrage propre	logs + healthchecks	Décidé POC
ENG-08	MCP SDK Python v2	2	serveur MCP	protocole 2026-07-28	conformance + clients cibles	rapport Inspector/suite	Recommandé
ENG-09	Stdio local, HTTP distant	2	transports	simplicité locale, accès distant	tests sur deux transports	rapports contrats	Recommandé
ENG-10	Jobs explicites	3	MongoDB + queue	MCP stateless, longues vidéos	reprise et polling	historique d'état	Recommandé

D. Qualité, sécurité et conformité

ID	Exigence	Phase	Fichier/composant	Méthode	Test	Preuve	Statut
QUA-01	Convention MISA	Toutes	tout Python	lint, review, typage	Ruff/Pyright	rapports CI	Convention fournie
QUA-02	Validation stricte	1	schémas	extra=forbid, validateurs métier	fuzz FEN/UCI/URL	tests unitaires	Inégal aujourd'hui
QUA-03	Contrats cohérents	1	schemas/API/MCP	enums uniques, erreurs standard	snapshot schemas	diff approuvé	Écarts relevés
QUA-04	Tests bout en bout	4	stack	cas nominaux et dégradés	campagne recette	dossier de preuves	À produire
SEC-01	Authentification/autorisation	2, 4	passerelle/MCP	OAuth/OIDC, scopes	token expiré, mauvais scope	rapport sécurité	Absent
SEC-02	Secrets	1	configuration	coffre/env, jamais dépôt/logs	scan secret	rapport CI	Absent
SEC-03	Protection SSRF/fichiers	3	ingestion	allowlist, taille, MIME, sandbox	URL interne, zip bomb, faux MIME	tests sécurité	Absent

ID	Exigence	Phase	Fichier/composant	Méthode	Test	Preuve	Statut
SEC-04	RGPD	0, 4	comptes/données	minimisation, rétention, droits	effacement/export	registre + preuve	À valider
LEG-01	Droits vidéo	0, 3	ingestion	provenance/licence obligatoire	actif sans licence	rejet + journal	Bloquant
OPS-01	Observabilité	1-4	tous services	logs structurés, métriques, traces	incident simulé	tableau de bord	À produire
OPS-02	Sauvegarde/reprise	4	Mongo/objets	RPO/RTO, test restauration	perte simulée	PV de restauration	À produire

Couverture actuelle des fichiers fournis

Domaine	Contrats présents	Implémentation présente	Tests présents	Conclusion
FEN/position	Oui, partiels	Non	Non	non prouvé
Ouvertures/coups	Oui	Non	Non	non prouvé
Stockfish	Réponses seulement	Non	Non	non prouvé
RAG	Documents/résultats	Non	Non	non prouvé
Vidéos	Métadonnées/recommandation	Non	Non	timestamp absent
Utilisateurs	Oui	Non	Non	RGPD à cadrer
FastAPI	Modèles de requête/réponse	Routes absentes	Non	surface incomplète
LangGraph	Non	Non	Non	absent du lot
MCP	Non	Non	Non	absent du lot

Définition de « couvert » pour la soutenance


- Couvert dossier : conception écrite et traçable, sans prétention d'exécution.
- Partiel existant : un contrat est présent mais la logique ou la validation métier manque.
- Prouvé : test exécuté, résultat archivé et version identifiée.
- Bloquant : aucune mise en production avant résolution.

Architecture MCP cible

1. Principes

- 1 Le domaine échiquéen reste indépendant du transport MCP et de FastAPI.
- 2 FastAPI et MCP appellent les mêmes services applicatifs.
- 3 Le serveur MCP est sans état de connexion ; tout état long porte un identifiant explicite.
- 4 Les outils renvoient des objets structurés conformes aux schémas.
- 5 Les appels externes sont bornés, mis en cache et observables.
- 6 Les sorties LLM ne peuvent pas rendre légal un coup qui ne l'est pas selon python-chess.
- 7 Les vidéos analysées ont une provenance et une autorisation documentées.

2. Vue logique



3. Couches

Couche	Responsabilité	Ne doit pas faire
Schémas	validation et sérialisation	logique métier ou HTTP
Domaine	règles FEN, coups, ouvertures	appels réseau
Application	cas d'usage, idempotence, politiques de repli	dépendre du frontend
Adaptateurs	Lichess, YouTube, Stockfish, MongoDB, Milvus	décider du parcours pédagogique
Orchestration	ordre, branches, timeouts	caler les erreurs ou les contrats
Interfaces	FastAPI et MCP	contenir des calculs complexes
Workers	traitement vidéo/embeddings	accepter des sources non autorisées

4. Catalogue MCP recommandé

Tools

Nom	Entrée principale	Sortie	Effet
chess.validate_fen	fen	position normalisée, erreurs	lecture seule
chess.identify_opening	fen	ECO, nom, variante, confiance	lecture seule
chess.recommend_moves	fen, budget moteur	coups, mode theory/engine	calcul borné
chess.analyze_position	fen, langue, difficulté	analyse agrégée et sources	calcul/lecture
video.search_position	fen, filtres	vidéos, segments, timestamps	lecture seule
video.start_indexing	référence d'actif autorisé	job_id	écrit un job
video.get_indexing_status	job_id	état, progression, erreur	lecture seule
video.cancel_indexing	job_id	état annulé	action sensible

Le POC peut se limiter aux six premiers en excluant annulation et ingestion distante si le corpus est préchargé.

Resources

URI	Contenu	Cache
chess://openings/{eco}	théorie, variantes, statistiques, sources	longue durée versionnée
chess://positions/{position_key}	analyse déterministe et liens	courte durée
chess://videos/{video_id}/timeline	segments position/timestamp autorisés	versionnée
chess://schemas/analysis-response	contrat de sortie	longue durée
chess://policies/video-ingestion	politique de provenance	longue durée

Prompts

Nom	Usage	Entrées
explain_opening	explication adaptée au niveau	ouverture, langue, difficulté
compare_candidate_moves	comparaison de coups légaux	position, candidats
build_training_plan	plan de travail sourcé	profil, ouvertures, durée

Les prompts n'exécutent pas de logique métier. Ils structurent la présentation d'informations déjà validées.

5. Séquence d'analyse

```
sequenceDiagram
    participant C as Client
    participant M as MCP/API
    participant W as LangGraph
    participant E as Chess services
    participant D as Data/RAG
    C->>M: analyze_position(fen)
    M->>E: validate + normalize
    E-->>M: position_key
    M->>W: run(request_id, position)
    W->>E: opening + Lichess
    alt théorie trouvée
        E-->>W: coups statistiques
    else hors théorie
        W->>E: Stockfish timebox
        E-->>W: MultiPV légales
    end
    W->>D: contexte RAG + vidéos
    D-->>W: sources + timestamps
    W-->>M: réponse structurée
    M-->>C: AnalysisResponse
```

6. Séquence d'indexation vidéo

```
sequenceDiagram
    participant C as Client autorisé
    participant M as MCP/API
    participant J as Job store
    participant V as Worker vidéo
    participant I as Index
    C->>M: start_indexing(asset_ref, rights_attestation)
    M->>J: create job_id
    M-->>C: accepted(job_id)
    V->>J: claim job
    V->>V: frames -> board -> pieces -> timeline
    V->>I: positions + segments + confidence
    V->>J: completed(metrics)
    C->>M: get_indexing_status(job_id)
    M-->>C: completed + summary
```

7. Workflow LangGraph

Noeuds recommandés :

- validate_input
- load_cached_analysis
- identify_opening
- query_lichess

- 5 route_theory_or_engine
- 6 run_stockfish
- 7 retrieve_documents
- 8 search_videos
- 9 compose_explanation
- 10 validate_output
- 11 persist_result

Branches obligatoires : FEN invalide, cache hit, Lichess vide, Lichess 429, Stockfish timeout, Milvus indisponible, LLM indisponible, aucun segment vidéo.

8. État et idempotence

- request_id : idempotence d'une analyse.
- job_id : cycle de vie d'une ingestion vidéo.
- asset_id : actif source et preuve de droits.
- position_key : recherche exacte normalisée.
- model_version : version vision/embedding.
- index_version : permet réindexation sans collision.

Index uniques proposés : request_id, (asset_id, index_version), (video_id, position_key, start_ms, model_version).

9. Transports et exposition

Local

- MCP sur stdio pour l'inspecteur et les hôtes locaux.
- FastAPI sur réseau Docker privé.
- services et bases via Docker Compose.

Distant

- MCP Streamable HTTP sur /mcp.
- FastAPI interne ou exposée sur /api/v1 selon besoin frontend.
- TLS à la passerelle.
- OAuth/OIDC et scopes par outil sensible.
- en-têtes MCP nécessaires à la version 2026-07-28 conservés par la passerelle.

10. Autorisation

Scopes minimaux :

- chess:read : validation, ouverture, analyse ;
- video:read : recherche et timelines ;
- video:index : démarrage d'un job autorisé ;
- video:cancel : annulation ;
- admin:corpus : politiques, réindexation et purge.

Les outils de lecture peuvent être accessibles à plus de clients que les outils d'ingestion. Toute action d'écriture journalise identité, actif, motif et résultat.

11. Compatibilité protocolaire

La cible est MCP 2026-07-28 avec le SDK Python v2. Le protocole a retiré les sessions et le handshake obligatoire ; les requêtes transportent les métadonnées nécessaires. Le catalogue doit rester compatible avec les clients réellement visés, vérifiés un par un.

L'extension Tasks n'est pas une dépendance du MVP. Les jobs métier explicites évitent un blocage de compatibilité et restent compréhensibles par le modèle.

12. Déploiement minimal

```
flowchart LR
    GW["Gateway TLS/OAuth"] --> SVC["API + MCP stateless"]
    SVC --> QUEUE["File de jobs"]
    QUEUE --> CPU["Workers Stockfish"]
    QUEUE --> GPU["Workers vidéo"]
    SVC --> DB["MongoDB"]
    SVC --> VDB["Milvus"]
    GPU --> OBJ["Stockage objet"]
```

13. Décisions à figer avant développement

- 1 clients MCP cibles et versions minimales ;
- 2 corpus vidéo et droits ;
- 3 politique de FEN partielle ;
- 4 SLO et budget Stockfish ;
- 5 fournisseur ou auto-hébergement de MongoDB/Milvus ;
- 6 fournisseur LLM/embeddings ou mode local ;
- 7 authentification du frontend et du MCP distant ;
- 8 durée de conservation des actifs et preuves.

Pipeline vidéo vers position et timestamp

Objectif

Créer un index permettant de retrouver dans une vidéo autorisée les intervalles où une position d'échecs apparaît, puis de produire un lien horodaté vers la plateforme source.

Entrées

Champ	Obligatoire	Description
asset_id	oui	identifiant interne stable
source_type	oui	upload, owned, licensed, partner
source_url	selon cas	URL d'origine, jamais utilisée pour contourner une restriction
youtube_video_id	non	identifiant servant au lien horodaté
rights_basis	oui	propriété, licence, consentement ou contrat
retention_policy	oui	durée et règle de suppression
expected_layout	non	aide au POC contrôlé
known_initial_fen	recommandé	nécessaire à une reconstruction complète fiable

Étapes détaillées

1. Admission

- authentifier l'émetteur ;
- vérifier taille, MIME réel, codec et durée ;
- refuser URL interne, protocole non autorisé et fichier suspect ;
- exiger provenance et base de droits ;
- calculer SHA-256 et détecter les doublons.

2. Décodage

- extraire FPS, résolution, durée et keyframes ;
- limiter CPU, mémoire, durée et espace temporaire ;
- isoler le transcodage dans un worker sans secret.

3. Échantillonnage

- cadence basse pendant les plans stables ;
- cadence plus élevée lors d'un changement détecté ;
- éviter de traiter chaque frame d'une vidéo longue ;
- conserver la correspondance exacte PTS -> millisecondes.

4. Détection d'échiquier

- boîte/coins et score ;
- suivi entre frames pour limiter les faux négatifs ;
- rectification homographique ;
- rejet si moins de 64 cases cohérentes.

5. Orientation

- détecter repères de coordonnées si visibles ;
- comparer légalité et continuité des orientations candidates ;
- indiquer unknown si le signal est insuffisant.

6. Classification des cases

Classes minimales : vide, roi/dame/tour/fou/cavalier/pion, blanc/noir. Conserver probabilités par case, pas seulement le meilleur label.

7. Lissage temporel

- vote glissant ;
- suppression des transitions d'animation ;
- détection d'un changement de une ou quelques cases ;
- pénalisation des apparitions impossibles.

8. Validation échiquéenne

- nombre et placement des rois ;
- nombre de pièces plausible ;
- transition compatible avec un coup légal ;
- promotion, roque et prise en passant traités explicitement ;
- aucune correction silencieuse : conserver prédiction brute et correction proposée.

9. Construction de position

États :

- `piece_placement_only` : seules les pièces sont connues ;
- `partial_fen` : placement + certains champs ;
- `full_fen` : six champs reconstruits avec preuve suffisante.

Une position complète exige soit une position initiale connue et une séquence légale suivie, soit des métadonnées fiables. Le système ne doit pas remplir arbitrairement $w - 0 \ 1$.

10. Segmentation

Regrouper des observations consécutives de même position :

- `start_ms` : première apparition stable ;
- `end_ms` : dernière apparition stable ;
- `best_frame_ms` : frame de preuve avec meilleur score ;
- `confidence` : confiance calibrée ;
- `evidence_frame_ref` : crop optionnel à rétention courte.

11. Indexation

Index exact sur `position_key`. Index secondaires sur ECO, pièces, source, langue, niveau, chaîne et date. Milvus n'est utilisé que pour la proximité lorsque la correspondance exacte échoue et que le produit l'autorise.

12. Résultat

Pour YouTube : https://www.youtube.com/watch?v={video_id}&t={seconds}s. Le système renvoie aussi la plage, la confiance, le type de position et la raison de classement.

Jeu de vérité terrain

Minimum POC recommandé :

- 20 à 50 vidéos autorisées ;
- 1 000 frames annotées ;
- 200 transitions de coups ;
- au moins 5 layouts ;
- captures avec overlays, thèmes clairs/sombres et animations ;
- cas négatifs sans échiquier.

Réserver les vidéos de test avant l'entraînement pour éviter la fuite de données.

Métriques

Niveau	Métrique	Seuil Go POC
Détection	rappel échiquier	$\geq 95 \%$
Géométrie	coins dans tolérance	$\geq 95 \%$
Cases	exactitude macro par classe	$\geq 95 \%$
Position	placement exact des 64 cases	$\geq 90 \%$
Séquence	transitions légales reconstruites	$\geq 90 \%$
Temps	erreur absolue P90	$\leq 2 \text{ s}$
Recherche	Recall@5 position vidéo	$\geq 90 \%$
Calibration	écart confiance/réalité	$\leq 5 \text{ points}$

Ces seuils valent pour le corpus cible, pas pour toutes les vidéos publiques.

Stratégies comparées

Approche	Avantages	Limites	Recommandation
Règles CV classiques	rapide, explicable	fragile aux thèmes/overlays	baseline
Détecteur + classifieur cases	bon compromis	données annotées nécessaires	POC recommandé
OCR notation/PGN visible	précision élevée si présent	dépend de l'interface vidéo	signal auxiliaire
Transcription/chapitres	peu coûteux	ne donne pas toujours la position	repli recommandation
Modèle multimodal général	mise en route rapide	coût, variabilité, reproductibilité	benchmark, pas source unique

Gestion des erreurs

- NO_BOARD_DETECTED
- UNSUPPORTED_LAYOUT
- LOW_CONFIDENCE_POSITION
- ILLEGAL_TRANSITION
- INCOMPLETE_FEN
- RIGHTS_NOT_VERIFIED
- VIDEO_DECODE_FAILED
- RESOURCE_LIMIT_EXCEEDED
- INDEX_WRITE_FAILED

Chaque erreur contient étape, actif, version, caractère relançable et détails non sensibles.

Coût unitaire à mesurer

Le pilote doit produire : secondes CPU/GPU par minute de vidéo, nombre de frames traitées, Go temporaires, coût cloud estimé, taux de retraitement et coût par position indexée. Sans ces mesures, l'OPEX vidéo reste une fourchette et non un budget.

Sécurité et conformité

1. Périmètre sensible

- comptes, emails et préférences ;
- secrets Lichess/YouTube/LLM et jetons OAuth ;
- fichiers vidéo potentiellement protégés ;
- prompts et documents RAG externes ;
- outils MCP déclenchant calcul ou écriture ;
- artefacts vision et journaux.

2. Menaces principales

Menace	Exemple	Mesure prioritaire
Accès non autorisé	lancement d'une ingestion coûteuse	OAuth/OIDC, scopes, quotas par identité
Injection d'outil	prompt demandant une action hors rôle	descriptions strictes, validation serveur, refus par défaut
SSRF	URL pointant vers réseau interne	pas d'URL arbitraire, allowlist, résolution/IP contrôlée
Fichier hostile	faux MP4, bombe de décompression	MIME réel, limites, sandbox, antivirus
Exfiltration	secret dans log ou réponse MCP	masquage, logs structurés, tests secrets
Déni de service	vidéos énormes ou Stockfish illimité	quotas, timeouts, file de jobs, concurrence bornée
Empoisonnement RAG	document malveillant	provenance, modération, séparation données/instructions
Fuite inter-utilisateur	timeline privée retournée à un autre compte	contrôle propriétaire/tenant à chaque lecture
Supply chain	dépendance compromise	lockfiles, SBOM, scans et mises à jour contrôlées

3. Contrôles MCP

- transport distant uniquement en TLS ;
- OAuth recommandé pour Streamable HTTP ;
- validation de l'émetteur et des audiences ;
- scopes par outil ;
- refus des arguments supplémentaires ;
- taille maximale des entrées/sorties ;
- rate limiting sur Mcp-Method et Mcp-Name ;
- journalisation des appels sensibles ;
- aucun secret dans les ressources ou prompts ;
- consentement explicite avant action destructive ou coûteuse.

4. Droits vidéo

Politique d'admission

Un actif n'est analysé que s'il possède : propriétaire ou licencié, source, date, périmètre de licence, preuve, durée de conservation et règle de retrait. L'attestation seule peut suffire pour un pilote interne à faible risque, mais une validation juridique est requise pour un service commercial.

YouTube

L'API officielle sert à retrouver les vidéos et leurs métadonnées. Les conditions d'utilisation ne constituent pas une autorisation générale de télécharger ou reproduire les contenus. Le produit doit privilégier le lecteur intégré et le lien horodaté. Toute analyse d'octets vidéo provenant de YouTube nécessite une base d'autorisation documentée séparément.

Retrait

Un retrait doit supprimer ou désactiver : fichier source, crops de preuve, segments d'index, embeddings associés et caches ; conserver seulement le journal minimal nécessaire à la preuve de suppression.

5. RGPD

À réaliser avant pilote externe :

- 1 identifier responsable et sous-traitants ;
- 2 documenter finalités et bases légales ;
- 3 limiter les données à l'identifiant, email nécessaire et préférences utiles ;
- 4 fixer les durées ;
- 5 permettre accès, rectification, export et effacement ;
- 6 sécuriser transit, repos et sauvegardes ;
- 7 encadrer transferts et fournisseurs ;
- 8 réaliser une AIPD si le contexte ou l'échelle l'exige ;
- 9 publier information et contact ;
- 10 tenir un registre des incidents.

Valeurs de départ à valider : analyses anonymisées 90 jours, comptes jusqu'à suppression + délai technique, journaux sécurité 180 jours, frames temporaires 24 heures, crops de preuve 30 jours maximum.

6. RAG et propriété intellectuelle

- ne pas indexer un document sans provenance ;
- stocker licence et règles d'usage ;
- limiter les extraits transmis au LLM ;
- afficher les sources ;
- traiter les documents comme données non fiables, jamais comme instructions système ;
- offrir désindexation et correction.

7. Secrets et configuration

- secrets injectés au runtime ;
- environnements séparés ;
- rotation et révocation ;
- aucune clé dans Dockerfile, Compose, frontend ou logs ;
- moindre privilège pour MongoDB, Milvus, stockage et API ;
- scan automatique du dépôt et des images.

8. Validation des entrées

- FEN validée par parseur métier ;

- UCI/SAN validés dans le contexte de la position ;
- URLs construites côté serveur à partir d'identifiants validés ;
- tailles de listes bornées ;
- langues et niveaux sous forme d'enums ;
- IDs au format documenté ;
- dates en types temporels, pas chaînes libres ;
- rejet des champs inconnus.

9. Journalisation et audit

Champs : timestamp UTC, correlation_id, identité pseudonymisée, outil/route, statut, durée, dépendance, quota, modèle/version. Exclure emails, jetons, vidéo brute, prompts privés et FEN si elle est liée à un utilisateur sans nécessité.

10. Checklist avant exposition distante

- ☐ OAuth/OIDC et scopes testés.
- ☐ TLS et en-têtes de sécurité configurés.
- ☐ quotas par utilisateur/outil.
- ☐ politiques de droits vidéo actives.
- ☐ export/effacement RGPD testés.
- ☐ secrets scannés et rotation testée.
- ☐ restauration de sauvegarde exécutée.
- ☐ SBOM et scans de vulnérabilités archivés.
- ☐ tests SSRF/fichiers hostiles exécutés.
- ☐ procédure incident et retrait documentée.
- ☐ revue juridique des sources et licences.

11. Avis

Cette section constitue une analyse de conception et non un avis juridique. Les droits vidéo, licences de corpus et obligations RGPD doivent être validés par la personne compétente avant mise en service externe.

Qualité, tests et recette

1. Stratégie

La qualité est organisée en pyramide : validation statique, tests unitaires, contrats, intégrations isolées, bout en bout, sécurité, charge et évaluation ML. Aucun score global unique ne remplace les seuils bloquants.

2. Chaîne CI proposée

- 1 format/lint ;
- 2 typage statique ;
- 3 tests unitaires avec couverture ;
- 4 validation JSON Schema/OpenAPI/YAML ;
- 5 tests contrats FastAPI/MCP ;
- 6 tests intégration avec services simulés ;
- 7 scans secrets, dépendances et images ;
- 8 build Docker reproductible ;
- 9 tests E2E sur environnement éphémère ;
- 10 publication des rapports de preuve.

Outils possibles : Ruff, Pyright, pytest, Hypothesis, Schemathesis, MCP Inspector/suite de conformité, Playwright, pip-audit, Trivy. Ils sont des choix d'implémentation, pas des exigences mission.

3. Tests statiques et schémas

- Python conforme à MISA ;
- Python cible explicitée, au minimum 3.11 recommandé pour StrEnum natif ;
- imports internes résolus ;
- aucune duplication de types sémantiques ;
- extra="forbid" homogène sur les entrées API ;
- champs temporels et URLs typés ;
- exemples OpenAPI/MCP validés ;
- compatibilité Pydantic verrouillée.

4. Tests domaine échecs

Cas	Attendu
FEN standard valide	normalisée sans changement sémantique
rang trop long, roi absent, symbole invalide	erreur structurée
coup UCI syntaxiquement correct mais illégal	rejet métier
roque sans droit	rejet
promotion valide/invalide	validation contextuelle
position issue d'une transposition	ouverture identifiée selon politique
statistiques	taux bornés et somme tolérée/validée
Stockfish timeout	réponse dégradée, worker libéré
PV	tous les coups rejouables légalement

Utiliser des tests de propriété pour générer des positions légales et vérifier que normalisation, sérialisation et rejeu préservent l'état.

5. Tests workflow

Branches minimales :

- cache hit ;
- théorie Lichess trouvée ;
- théorie absente -> Stockfish ;
- Lichess 429 -> pause/circuit/cache ;
- Stockfish indisponible ;
- Milvus indisponible ;
- LLM indisponible ;
- MongoDB indisponible avant/après calcul ;
- YouTube quota épuisé ;
- aucun document ou aucune vidéo ;
- répétition du même request_id ;
- annulation/reprise d'un job vidéo.

Chaque noeud LangGraph doit être testable indépendamment. Les transitions sont vérifiées par snapshot de trace, sans dépendre du texte exact du LLM.

6. Tests MCP

- découverte des primitives ;
- schémas d'entrée et de sortie ;
- champ manquant, supplémentaire ou trop grand ;
- outil inconnu ;
- ressource inconnue ;
- cache metadata des listes/ressources ;
- stdio et Streamable HTTP ;
- version protocolaire supportée et refus propre d'une version incompatible ;
- absence d'état implicite entre deux instances ;
- scopes corrects/incorrects ;
- propagation des correlation IDs ;
- outil d'écriture soumis à autorisation et audit.

7. Tests FastAPI

- génération OpenAPI ;
- cohérence codes HTTP et modèle ErrorResponse ;
- idempotence ;
- limites de taille ;
- timeouts ;

- CORS limité ;
- auth ;
- health/readiness distingués ;
- même réponse métier via API et MCP, hors enveloppe de transport.

8. Évaluation RAG

Construire 50 à 100 questions annotées avec documents attendus. Mesurer Recall@5, MRR/NDCG, taux de réponse sourcée, fidélité au contexte et abstention lorsque le corpus ne répond pas.

Seuils POC : Recall@5 $\geq 0,80$, sources correctes $\geq 90\%$, aucune citation inventée dans le jeu de recette.

9. Évaluation vidéo

Séparer entraînement, validation et test par vidéo/chaîne/layout, pas par frames aléatoires. Rapporter par sous-groupe : 2D/3D, thème, résolution, overlays, animation, orientation.

Seuils bloquants : rappel échiquier $\geq 95\%$, placement exact $\geq 90\%$, Recall@5 vidéo $\geq 90\%$, erreur timestamp P90 ≤ 2 s. Présenter aussi les intervalles de confiance et le nombre d'exemples.

10. Performance et charge

Scénarios : 10/50/200 analyses concurrentes, pool Stockfish saturé, 10 jobs vidéo, cache froid/chaud, dépendance lente. Mesurer P50/P95/P99, débit, mémoire, CPU/GPU, files d'attente et taux d'erreur.

Les appels Lichess restent sérialisés indépendamment de la charge interne. Un test spécifique confirme l'attente d'une minute après 429.

11. Sécurité

- contrôle d'accès horizontal ;
- injection dans prompts/documents ;
- SSRF ;
- traversée de chemin ;
- fichier vidéo hostile ;
- épuisement ressources ;
- secrets ;
- dépendances ;
- journalisation de données personnelles ;
- consentement pour annulation/purge.

12. Matrice de recette

Le CSV 05_preuves/matrice-recette.csv sert au suivi. Colonnes obligatoires : identifiant, exigence, cas, précondition, entrée, attendu, obtenu, statut, version, preuve, date, responsable.

13. Définition de Done

Une fonctionnalité est terminée lorsque :

- code et contrats sont relus ;
- tests requis passent ;
- métriques sont sous les seuils ;

- logs/erreurs sont exploitables ;
- sécurité et droits sont respectés ;
- documentation est mise à jour ;
- preuve est liée à l'exigence ;
- démonstration peut être reproduite depuis un environnement propre.

14. Preuves à ne pas surévaluer

- compilation seule ;
- capture d'écran sans entrée/version ;
- exemple unique réussi ;
- métrique d'entraînement ;
- réponse LLM jugée « plausible » ;
- schéma Pydantic sans route ni test ;
- fichier déclaré mais absent du lot.

Plan, charges et budget

1. Hypothèses

- jour homme de 7 heures ;
- taux indicatifs HT : backend/MCP 700 EUR, ML/CV 750 EUR, frontend 600 EUR, DevOps/sécurité 700 EUR, QA 550 EUR, produit/UX 600 EUR ;
- équipe disponible en parallèle ;
- corpus vidéo pilote fourni légalement ;
- pas de refonte majeure de la stack ;
- pas de support 24/7 ;
- fourchettes incluant revue et documentation, avec aléa technique selon niveau.

2. Lots MVP détaillés

Lot	Livrables	Charge basse	Charge haute	Dépendances
L0 Cadrage/droits	périmètre, corpus, DPIA screening, critères	8 j	12 j	aucune
L1 Architecture/contrats	ADR, schémas, OpenAPI, catalogue MCP	8 j	12 j	L0
L2 Coeur échecs	FEN, ECO, Lichess, Stockfish, erreurs/cache	18 j	26 j	L1
L3 Orchestration/API	LangGraph, FastAPI, idempotence	12 j	18 j	L2
L4 RAG	ingestion, Milvus, évaluation, citations	12 j	18 j	L1
L5 Serveur MCP	tools/resources/prompts, transports, auth	10 j	15 j	L2-L4
L6 Vidéo POC	ingestion, CV, reconstruction, index	28 j	42 j	L0-L1
L7 Frontend	échiquier, résultats, jobs, erreurs	14 j	20 j	L3/L5
L8 DevOps/observabilité	Compose, CI/CD, logs, backups	10 j	15 j	transversal
L9 Sécurité/conformité	auth, scans, rétention, retrait	7 j	12 j	L0
L10 QA/recette/pilote	campagnes, charge, preuves, soutenance	12 j	18 j	tous
Total brut		139 j	208 j	

Ce total correspond à un MVP ambitieux avec pipeline vidéo. L'objectif budgétaire de 115 à 165 j.h suppose réemploi de composants, corpus contrôlé et limitation du frontend. Un arbitrage de périmètre est donc nécessaire pour tenir la borne basse.

3. Scénarios d'investissement

Scénario POC - 30 à 45 kEUR

- FEN/opening/Lichess/Stockfish ;
- RAG réduit ;
- serveur MCP local + HTTP de test ;
- 20 à 50 vidéos pré-autorisées ;
- un à deux layouts ;
- UI minimale ;
- preuves des principaux critères.

Scénario MVP - 75 à 115 kEUR

- comptes/préférences ;

- traitement asynchrone ;
- auth et observabilité ;
- 5 layouts et corpus annoté ;
- déploiement pilote ;
- procédures de retrait et restauration.

Scénario bêta - 145 à 220 kEUR

- résilience et scalabilité ;
- corpus élargi ;
- sécurité renforcée ;
- compatibilité clients MCP ciblés ;
- supervision, runbooks et pilote multi-utilisateurs.

4. Planning indicatif MVP

Période	Travaux	Jalon
Semaines 1-3	cadrage droits, données, benchmark vision, contrats	Porte G0 : corpus et architecture
Semaines 4-7	coeur échecs, API, cache, erreurs	Porte G1 : analyse déterministe
Semaines 6-9	RAG, MCP, contrats et auth	Porte G2 : client MCP E2E
Semaines 8-15	pipeline vidéo contrôlé	Porte G3 : seuils vision/timestamp
Semaines 12-17	frontend, comptes, observabilité	Porte G4 : pilote intégré
Semaines 18-20	sécurité, charge, recette, preuves	Porte G5 : Go pilote

Délai réaliste : 4 à 6 mois avec 3 à 4 personnes équivalent temps plein. Une personne seule doit raisonner en charge et non en calendrier : environ 7 à 10 mois pour un périmètre réduit.

5. RACI minimal

Activité	Produit	Architecte/backend	ML/CV	Frontend	DevOps/sécu	QA
exigences et Go/No-Go	A/R	C	C	C	C	C
contrats MCP/API	C	A/R	C	C	C	C
coeur échecs	C	A/R	I	C	C	C
pipeline vidéo	C	C	A/R	I	C	C
sécurité/conformité	C	C	C	I	A/R	C
recette et preuves	A	R	R	R	R	R

A = accountable, R = responsable, C = consulted, I = informed.

6. OPEX et facteurs

Facteur	Formule de pilotage
CPU API	requêtes x durée CPU x tarif instance
Stockfish	analyses x secondes moteur x coeurs
Vidéo GPU	heures vidéo x frames/min x coût GPU/frame
Stockage	Go source autorisée + preuves + sauvegardes
Milvus	nombre de vecteurs x dimension x réplication
LLM	tokens entrée/sortie par analyse
Trafic	réponses, miniatures, téléchargements autorisés

Mettre des budgets/quotas par utilisateur et alerter à 50/80/100 %.

7. Sensibilités

Variation	Effet probable
durée vidéo x10	coût GPU et stockage presque linéaires sans échantillonnage
layouts de 2 à 20	annotation et généralisation fortement accrues
analyse Stockfish 2 s -> 10 s	capacité moteur divisée approximativement par 5
cache hit 20 % -> 80 %	forte réduction APIs/LLM/Stockfish
conservation de toutes les frames	hausse majeure stockage et risque juridique
corpus partenaire avec PGN	baisse forte du coût vision et hausse précision

8. Réserves

Ajouter 15 à 25 % de contingence au budget validé tant que le benchmark vision et les droits du corpus ne sont pas clos. Toute estimation ferme doit partir du volume : heures vidéo/mois, analyses/jour, utilisateurs actifs, clients MCP, régions et SLA.

Registre des risques et alternatives

Échelle : probabilité P et impact I de 1 à 5 ; criticité = P x I.

ID	Risque	P	I	Score	Prévention / réduction	Déclencheur	Propriétaire
R01	droits vidéo insuffisants	4	5	20	corpus détenu/licencié, preuve obligatoire	actif sans preuve	produit/juridique
R02	FEN complète inférable d'une frame	5	4	20	état partiel, suivi temporel, FEN initiale	champs inventés ou incohérents	ML/backend
R03	généralisation vision faible	4	4	corpus contrôlé, benchmark, métriques par layout	placement exact < 90 %	ML/CV	
R04	quota/rate limit Lichess	3	4	sérialisation, cache, pause 60 s après 429	429 ou latence élevée	backend	
R05	quota YouTube	3	3	cache, budget, audit si extension	consommation > 80 %	backend/ops	
R06	hallucination de coups/sources	3	5	légalité déterministe, sorties structurées, citations	coup illégal ou source absente	IA/QA	
R07	coût GPU excessif	4	4	échantillonnage adaptatif, budget, corpus PGN	coût/heure > seuil	ML/ops	
R08	divergence API/MCP	3	3	mêmes services, contrats et tests snapshot	réponses sémantiques différentes	architecte	
R09	contrats Pydantic incohérents	4	3	enums uniques, revue migration, version API	échec sérialisation	backend	
R10	traitement vidéo hostile	3	5	sandbox, limites, antivirus, codecs contrôlés	crash/épuisement	sécurité	
R11	fuite de données utilisateur	2	5	tenant checks, chiffrement, tests horizontaux	accès croisé	sécurité	
R12	dépendance service externe	4	3	timeouts, circuit breaker, mode dégradé	5xx/timeout	backend/ops	
R13	Milvus surdimensionné	3	2	benchmark vs alternative simple	faible corpus/coût élevé	architecte	
R14	extension MCP non supportée	3	3	jobs métier, compatibilité client, pin versions	test client échoue	MCP	
R15	manque de vérité terrain	4	4	annotation avant modèle, split propre	métriques non crédibles	produit/ML	
R16	versioning modèle/index	3	4	model_version, index_version, réindexation	résultats incompatibles	ML/data	
R17	performance Stockfish	3	3	timebox, pool workers, cache	file d'attente	backend/ops	
R18	non-conformité RGPD	3	5	registre, rétention, droits, minimisation	demande d'effacement impossible	produit/sécu	

Matrice de traitement

- score 15-25 : blocage ou réduction avant pilote ;
- score 8-14 : plan obligatoire et suivi hebdomadaire ;
- score 1-7 : accepter ou surveiller.

Alternatives de périmètre

Option	Description	Coût	Risque	Valeur	Avis
O1 Core sans vision	FEN, théorie, moteur, RAG, vidéos par métadonnées	faible	faible	moyenne	repli sûr
O2 Corpus partenaire	vidéos + PGN/timelines fournis	moyen	faible	élevée	meilleure option MVP
O3 Vision contrôlée	1-5 layouts autorisés	moyen	moyen	élevée	POC recommandé

Option	Description	Coût	Risque	Valeur	Avis
O4 Vision généraliste	toute vidéo publique	très élevé	très élevé	potentiellement élevée	No-Go initial
O5 Base vectorielle managée	Zilliz/Milvus géré	moyen OPEX	faible ops	élevée	si petite équipe
O6 Milvus auto-hébergé	contrôle total	ops élevé	moyen	élevée	si compétence infra
O7 Recherche exacte d'abord	hash position + Mongo	faible	faible	élevée	obligatoire
O8 Tout vectoriel	proximité comme mécanisme principal	moyen	moyen	moyenne	déconseillé pour exactitude

Plans de contingence

Vision sous les seuils

Limiter aux layouts performants, exiger PGN ou overlay lisible, offrir recherche par ouverture/chapitre et conserver la position manuelle.

Droits non obtenus

Supprimer ingestion vidéo tierce ; ne garder que liens et métadonnées officielles ou vidéos propres. Le cœur Chess Agent reste viable.

Coûts trop élevés

Traitement différé, cadence réduite, cache, modèles CPU, suppression des artefacts intermédiaires, quotas par compte et corpus éditorialisé.

MCP client incompatible

Geler la version SDK, réduire aux primitives communes, utiliser l'API FastAPI pour le frontend et maintenir des tests par client cible.

Revue

Le registre est revu à chaque porte G0-G5. Toute criticité ≥ 15 possède un responsable, une date et une preuve de réduction avant passage de porte.

Décisions, hypothèses et questions

Décisions issues des échanges

ID	Décision	Conséquence
D01	projet orienté assistant d'ouvertures d'échecs	priorité au parcours FEN et pédagogie
D02	stack FastAPI, LangGraph, Milvus, MongoDB, Stockfish, Lichess/YouTube, Angular/ngx-chessboard	architecture et compétences alignées
D03	théorie Lichess puis repli Stockfish	branche explicite et testée
D04	RAG pour enrichir les explications	corpus, embeddings et métriques nécessaires
D05	pipeline vidéo frames -> échiquier -> position -> timestamp	lot ML/CV distinct et mesuré
D06	exposition par serveur MCP	catalogue tools/resources/prompts
D07	Docker Compose et dépôt Git pour le POC	reproductibilité locale
D08	couvrir 100 % de l'énoncé avec traçabilité et preuve	matrice obligatoire
D09	distinguer exigences mission et choix d'ingénierie	documents séparés et IDs distincts
D10	respecter la convention MISA dans tout Python	CI et revue style

Recommandations de cette étude

ID	Recommandation	Motif
R-A01	cible MCP 2026-07-28 et SDK Python v2	version stable courante au 18 août 2026
R-A02	stdio local, Streamable HTTP distant	simplicité et conformité
R-A03	jobs vidéo par job_id explicite	protocole sans session et traitement long
R-A04	recherche exacte avant vectorielle	exactitude d'une position déterministe
R-A05	corpus détenu/licencié/partenaire	droits et qualité
R-A06	représenter position partielle	impossibilité d'inférer une FEN complète d'une image seule
R-A07	séparer workers Stockfish et vidéo	profils CPU/GPU différents
R-A08	même couche applicative pour API et MCP	éviter divergence métier
R-A09	ne pas dépendre de MCP Tasks au MVP	compatibilité et maturité à valider
R-A10	portes Go/No-Go quantitatives	limiter le risque avant investissement

Hypothèses de chiffrage

ID	Hypothèse	Sensibilité
H01	20 à 50 vidéos POC autorisées	forte sur annotation/vision
H02	1 à 5 layouts cibles	très forte sur qualité
H03	45 à 65 j.h pour le POC	forte selon réemploi réel
H04	550 à 750 EUR/jour	linéaire sur investissement
H05	traitement batch, pas live	forte sur infra
H06	petit trafic pilote	forte sur OPEX
H07	disponibilité 99,5 % MVP	moyenne sur ops
H08	vidéos conservées seulement si autorisées	réduit coût/risque
H09	LLM et embeddings interchangeables	dépend des contrats/qualité
H10	corpus documentaire licencié	bloquant pour RAG public

Questions à arbitrer

Priorité	Question	Décideur	Échéance
Bloquante	quelles vidéos et quels droits exacts ?	produit/juridique	G0
Bloquante	la mission exige-t-elle une FEN complète ou le placement suffit-il ?	commanditaire	G0
Bloquante	quels clients MCP doivent être compatibles ?	architecte/produit	G0
Haute	quel volume vidéo/mois et analyses/jour ?	produit	G0
Haute	quels SLO, régions et contraintes d'hébergement ?	produit/ops	G0
Haute	quels layouts et langues prioritaires ?	produit/ML	G0
Haute	quel fournisseur LLM ou mode local ?	architecte	G1
Haute	authentification interne ou utilisateurs externes ?	produit/sécu	G1
Moyenne	Milvus managé ou auto-hébergé ?	ops/finance	G1
Moyenne	durée de conservation comptes/vidéos/logs ?	juridique/produit	G1
Moyenne	modèle économique et niveau gratuit ?	direction	après POC
Moyenne	faut-il expliquer les coups en français uniquement ?	produit	G1

ADR à créer pendant le projet

- ADR-001 version MCP et matrice clients ;
- ADR-002 sémantique de position partielle ;
- ADR-003 stratégie vidéo et droits ;
- ADR-004 orchestration LangGraph ;
- ADR-005 stockage exact/vectoriel ;
- ADR-006 timeouts, cache et replis ;
- ADR-007 auth et multi-tenant ;
- ADR-008 versioning des modèles et index ;
- ADR-009 politique de rétention ;
- ADR-010 hébergement et observabilité.

Audit des fichiers fournis

1. Inventaire

Fichier reçu	Rôle observé	Points utiles	Limites majeures
MISA.txt	convention Python	structure, typage, lisibilité, responsabilité	pas de règles tests/sécurité/async spécifiques
evaluation(1).py	évaluations Stockfish/IA	score, type, profondeur, PV	cohérence PV et score à préciser
user(1).py	utilisateurs/préférences	personnalisation	RGPD/auth/persistance absents
document(1).py	documents RAG	metadata, chunks, similarité	licence, embedding/version absents
analysis(1).py	requête/réponse agrégée	contrat produit principal	enums dupliqués, idempotence absente
video(1).py	vidéos/recommandations	plateforme indépendante	aucun timestamp, segment, provenance ou job
move(1).py	coups/statistiques	UCI/SAN, légalité décrite	validation seulement syntaxique par longueur
error(1).py	erreurs	code/message/HTTP	intégration incohérente avec AnalysisResponse
opening(1).py	ouverture/théorie	ECO, variantes, plans	validation ECO et sources absentes
position(1).py	FEN/position	champs principaux	FEN faiblement validée
enums(1).py	valeurs communes	centralisation	doublons et non-utilisation dans analysis

2. Résultat global

Les modules constituent une base lisible de DTO Pydantic. Ils montrent le domaine envisagé, mais ne prouvent pas :

- une route FastAPI ;
- un service métier ;
- un graphe LangGraph ;
- un client Lichess/YouTube ;
- Stockfish lancé via UCI ;
- MongoDB ou Milvus configurés ;
- un pipeline vidéo ;
- un serveur MCP ;
- des tests ;
- un déploiement Docker.

Le statut correct est donc conception partielle des contrats.

3. Écarts transverses

3.1 Enums dupliqués

analysis(1).py définit AnalysisMode et AnalysisStatus sous forme de Literal, alors que enums(1).py fournit des StrEnum. Les deux ne sont pas équivalents : l'enum inclut RUNNING, le Literal non. Il faut une source unique.

PieceColor et ChessColor portent les mêmes valeurs et descriptions. Conserver un seul type sauf différence métier documentée.

3.2 Validation métier insuffisante

- FenRequest.fen vérifie seulement une longueur minimale ;
- Move.uci vérifie une longueur 4-5 sans pattern ni légalité ;

- `from_square/to_square` acceptent n'importe quels deux caractères ;
- `eco` n'est pas contraint par un pattern A00-E99 ;
- URLs et emails sont inégalement typés ;
- dates vidéo/document sont des chaînes libres ;
- taux de résultats ne sont pas contrôlés comme ensemble.

La validation Pydantic doit être complétée par `python-chess` et des validateurs contextuels.

3.3 Configuration Pydantic inégale

Certains modèles interdisent les champs supplémentaires et/ou sont figés ; d'autres non. Les entrées externes doivent refuser les champs inconnus. La mutabilité doit refléter le rôle, pas varier sans justification.

3.4 Erreurs incohérentes

`ErrorResponse` définit une enveloppe structurée, mais `AnalysisResponse.error` est une simple chaîne. Choisir un modèle d'erreur unique pour FastAPI et mapper proprement vers les erreurs MCP.

3.5 Idempotence et traçabilité absentes

`AnalysisRequest` ne contient ni `request_id`, ni utilisateur, langue, difficulté, budget moteur ou options. Les discussions antérieures évoquaient une sauvegarde idempotente ; elle n'est pas visible dans les fichiers reçus.

3.6 Sources et versions absentes

Une réponse pédagogique doit indiquer : provenance Lichess/Stockfish/RAG/YouTube, timestamp d'accès, version moteur, profondeur/temps, document/chunk et score. Les contrats ne couvrent pas entièrement cette traçabilité.

4. Écarts par fichier

`evaluation(1).py`

- `Evaluation.score`: float ne précise pas l'unité selon CENTIPAWN ou MATE ; un entier ou union discriminée serait plus sûr.
- `PrincipalVariation` embarque une `Evaluation`, et `EngineAnalysis` en embarque une autre ; définir si elles doivent être identiques.
- `BestMove` contient déjà `principal_variation`, créant une autre duplication.
- limites maximales de profondeur, noeuds et temps non définies.

`user(1).py`

- identifiant format libre ;
- `preferred_color` est une chaîne au lieu de `ChessColor` ;
- langue libre au lieu d'un code validé ;
- email personnel sans politique de rétention ;
- absence de consentements/rôles/tenant si nécessaires.

`document(1).py`

- `publication_date` devrait être un type date/temps ;
- `url` devrait être validée ;
- licence, droits, hash, version d'embedding et modèle manquent ;
- `Document.content` intégral dans chaque résultat peut gonfler les réponses ;

- RetrievedDocument devrait privilégier le chunk/extrait sourcé.

`analysis(1).py`

- duplication de modes/statuts ;
- AnalysisRequest trop minimal ;
- pas de request_id, created_at, sources, warnings, partial ;
- listes Document et Video perdent similarité/raison de recommandation ;
- réponse success/error non discriminée, ce qui autorise des combinaisons incohérentes ;
- erreurs standard non réutilisées.

`video(1).py`

Écart critique par rapport à la mission : aucun champ timestamp, start_ms, end_ms, position_key, fen, confidence, rights_basis, asset_id, job_id ou index_version. Il faut ajouter des contrats dédiés sans surcharger Video.

published_at devrait être temporel ; URLs validées ; la dépendance au nombre d'abonnés est volatile et peut être absente.

`move(1).py`

- cohérence UCI/SAN/cases non vérifiée ;
- promotion non discriminée ;
- score et type d'évaluation dupliquent Evaluation ;
- taux peuvent totaliser autre chose que 100 ;
- aucune source/période pour les statistiques.

`error(1).py`

- nom Error très générique ;
- absence de correlation_id, retryable, details structurés et dépendance ;
- status_code HTTP ne s'applique pas directement au transport MCP ; séparer erreur métier et mapping transport.

`opening(1).py`

- ECO et FEN non validés ;
- coups sans type notation ;
- statistiques dupliquées avec celles des coups ;
- théorie sans sources ;
- difficulté par défaut peut être arbitraire.

`position(1).py`

- validation FEN faible ;
- active_color blanc/noir nécessite un mapping vers w/b ;
- castling rights chaîne libre ;
- en passant chaîne libre ;
- état nul/game over peut être incohérent sans calcul python-chess ;
- import multi-ligne inutilement développé au regard de deux symboles, point mineur de style.

enums(1).py

- PieceColor/ChessColor dupliqués ;
- SearchSource mélange base, APIs et moteur, utiles mais de natures différentes ;
- types vidéo/états de job/position partielle absents ;
- ligne vide après les commentaires de section à homogénéiser selon MISA.

5. Schémas à ajouter

- AnalysisOptions, AnalysisSource, AnalysisWarning ;
- VideoAsset, RightsMetadata ;
- VideoIndexJob, VideoIndexStatus ;
- BoardObservation, DetectedPosition ;
- VideoPositionSegment, VideoPositionMatch ;
- ModelProvenance, IndexProvenance ;
- ServiceError séparé du mapping HTTP/MCP ;
- unions discriminées success/error et partial/full position.

Un exemple JSON contractuel figure dans 02_contrats/schemas-video-index.json.

6. Priorités de correction

Priorité	Action	Motif
P0	unifier enums et erreurs	évite divergence de contrat
P0	ajouter provenance/droits/timestamps/jobs	indispensable à la mission vidéo
P0	valider FEN/coups par python-chess	sûreté fonctionnelle
P1	ajouter request_id, sources, warnings	idempotence et preuve
P1	unions discriminées de réponses	états impossibles éliminés
P1	types URL/date/langue/IDs	validation externe
P2	réduire duplications statistiques/PV	maintenabilité
P2	homogénéiser frozen/extra	cohérence MISA

7. Conclusion d'audit

La base est exploitable pour démarrer une refonte de contrats, pas pour affirmer la faisabilité déjà démontrée. Le premier sprint technique doit corriger les P0 avant d'exposer une API ou un serveur MCP stable.

Soutenance et dossier de preuves

1. Trame de présentation, 15 minutes

Temps	Sujet	Message clé	Preuve montrée
1 min	problème	retrouver l'explication et le bon passage vidéo	parcours utilisateur
2 min	périmètre	coeur échecs + MCP + vidéo contrôlée	matrice exigences
2 min	architecture	mêmes services via API et MCP	diagramme logique
3 min	démonstration	FEN -> ouverture -> coups -> sources -> timestamp	journal E2E
2 min	difficulté vidéo	position partielle et reconstruction temporelle	exemples annotés
2 min	faisabilité	score, budget, planning	tableaux synthèse
2 min	risques	droits vidéo et métriques Go/No-Go	registre risques
1 min	décision	Go conditionnel par paliers	portes G0-G5

2. Démonstration idéale

- Démarrer un environnement propre.
- Afficher les versions et healthchecks.
- Soumettre une FEN connue via client MCP.
- Montrer identification ECO et source de théorie.
- Soumettre une position hors théorie et montrer le repli Stockfish.
- Afficher un document RAG avec source.
- Rechercher la position dans une vidéo autorisée.
- Ouvrir le lien au timestamp calculé.
- Répéter le même request_id et prouver l'idempotence.
- Simuler un 429 Lichess ou un service indisponible et montrer la réponse dégradée.

3. Dossier de preuve par exigence

Arborescence recommandée :

```

preuves/
  MIS-01/
    README.md
    input.json
    result.json
    logs.txt
    capture.png
  APP-03/
  SEC-01/
  ...

```

Chaque README.md précise version Git, environnement, commande, attendu, obtenu, date et responsable.

4. Questions probables et réponses

Pourquoi MCP en plus de FastAPI ?

FastAPI sert le frontend et les intégrations HTTP classiques. MCP rend les mêmes capacités découvrables et appelables de manière structurée par des hôtes IA, avec tools, resources et prompts. La logique métier n'est pas dupliquée.

Peut-on réellement produire une FEN depuis une image ?

On peut reconnaître la disposition des pièces. Les autres champs FEN ne sont pas toujours visibles. Le système les reconstruit seulement grâce à la séquence et à un état initial fiable ; sinon il annonce une position partielle.

Pourquoi ne pas télécharger toutes les vidéos YouTube ?

Parce que l'accès au lecteur ou aux métadonnées n'accorde pas automatiquement le droit de télécharger et d'analyser les octets. Le MVP utilise des vidéos détenues/licenciées et renvoie un lien YouTube horodaté.

Pourquoi Lichess puis Stockfish ?

La théorie et les statistiques sont plus pédagogiques dans les positions connues. Stockfish fournit un repli déterministe hors base, sous budget de calcul.

Pourquoi Milvus si MongoDB existe ?

MongoDB gère documents et état applicatif ; Milvus sert la similarité vectorielle. Pour un très petit corpus, une alternative plus simple doit être benchmarkée.

Comment évitez-vous les hallucinations ?

Les coups sont validés/rejoués avec python-chess, les évaluations viennent de Stockfish/Lichess et les explications citent les chunks retrouvés. Le LLM présente, il ne décide pas de la légalité.

5. Captures/rapports indispensables

- matrice de tests avec statuts ;
- rapport Pyright/Ruff ;
- tests unitaires et couverture ;
- contrats OpenAPI/MCP ;
- trace LangGraph nominale et dégradée ;
- rapport qualité RAG ;
- rapport CV par sous-groupe ;
- mesure timestamp ;
- test rate limit Lichess ;
- test auth/scopes ;
- scan secrets/vulnérabilités ;
- test de restauration ;
- preuve de droits du corpus, expurgée si confidentielle.

6. Checklist avant soutenance

- [] aucune affirmation « développé » sans preuve exécutable ;
- [] version et date sur tous les rapports ;
- [] démonstration enregistrée en secours ;
- [] corpus test distinct de l'entraînement ;
- [] deux cas d'échec expliqués ;
- [] budget relié aux hypothèses ;
- [] décisions et hypothèses clairement séparées ;
- [] tous les IDs d'exigence ont une preuve ou un statut à faire ;
- [] lien horodaté testé ;

- [] droits du média de démonstration confirmés.

7. Formulation de conclusion

« Le coeur Chess Agent et son exposition MCP sont techniquement faisables. La valeur différenciante, la recherche d'une position dans une vidéo, est faisable sur corpus contrôlé mais reste conditionnée par les droits et par des seuils mesurés de vision et de timestamp. Nous proposons un investissement progressif, avec une porte de décision après trois semaines de réduction des risques. »

Inventaire des sources

1. Fichiers fournis

N°	Nom reçu	Copie dans le dossier	Usage
1	MISA.txt	04_sources_fournies/MISA.txt	convention Python
2	evaluation(1).py	04_sources_fournies/evaluation.py	schémas évaluation
3	user(1).py	04_sources_fournies/user.py	schémas utilisateur
4	document(1).py	04_sources_fournies/document.py	schémas RAG
5	analysis(1).py	04_sources_fournies/analysis.py	requête/réponse analyse
6	video(1).py	04_sources_fournies/video.py	vidéos et recommandations
7	move(1).py	04_sources_fournies/move.py	coups et statistiques
8	error(1).py	04_sources_fournies/error.py	erreurs
9	opening(1).py	04_sources_fournies/opening.py	ouvertures
10	position(1).py	04_sources_fournies/position.py	position/FEN
11	enums(1).py	04_sources_fournies/enums.py	enums communs

Les copies sont fidèles au contenu reçu ; seul le nom est normalisé pour faciliter la lecture.

2. Contexte consolidé des échanges

- mission : concevoir un système de stockage vidéo, extraction de frames, détection d'échiquier, position/FEN et recherche de lien horodaté ;
- stack : FastAPI, LangGraph, Milvus, MongoDB, Stockfish, APIs Lichess/YouTube, Angular/ngx-chessboard, Docker Compose, Git ;
- workflow : FEN -> ouverture -> Lichess -> repli Stockfish -> RAG -> vidéos -> UI ;
- contrainte : couverture à 100 % de l'énoncé avec phase, fichiers, méthode, test et preuve ;
- contrainte : séparer exigences mission et choix d'ingénierie.

3. Références officielles consultées

Consultation : 18 août 2026.

Model Context Protocol

- Spécification 2026-07-28 : <https://modelcontextprotocol.io/specification/2026-07-28>
- Architecture : <https://modelcontextprotocol.io/docs/2026-07-28/learn/architecture>
- Tools : <https://modelcontextprotocol.io/specification/2026-07-28/server/tools>
- Resources : <https://modelcontextprotocol.io/specification/2026-07-28/server/resources>
- Changelog : <https://modelcontextprotocol.io/specification/2026-07-28/changelog>
- SDK Python officiel : <https://github.com/modelcontextprotocol/python-sdk>

Points retenus : coeur sans session, requêtes autonomes, découverte, tools/resources/prompts, transports stdio et Streamable HTTP, durcissement de l'autorisation, SDK Python v2 stable.

Lichess

- API : <https://lichess.org/api>
- Conseils API et rate limiting : <https://lichess.org/page/api-tips>

Points retenus : un seul appel à la fois ; après HTTP 429, attendre une minute complète avant reprise.

YouTube

- Démarrage API : <https://developers.google.com/youtube/v3/getting-started>
- Quotas/audits : https://developers.google.com/youtube/v3/guides/quota_and_compliance_audits
- Coût des méthodes : https://developers.google.com/youtube/v3/determine_quota_cost
- Conditions YouTube : <https://www.youtube.com/static?template=terms>

Points retenus : quotas par projet/méthode, audit pour extension, limites d'usage et absence de droit général de télécharger/reproduire les contenus.

Données et coûts

- MongoDB Atlas : <https://www.mongodb.com/pricing>
- Zilliz Cloud : <https://zilliz.com/pricing>
- Guide de prix Zilliz : <https://zilliz.com/pricing/pricing-guide>

Les prix publics changent ; le budget du dossier utilise des fourchettes et doit être recalculé avec régions, SLA et volumes.

4. Sources à ajouter avant développement

- énoncé officiel intégral et critères d'évaluation ;
- licences du corpus documentaire ;
- licences et preuves de droits des vidéos ;
- matrice des clients MCP cibles ;
- versions exactes Python/Angular/ngx-chessboard/LangGraph/Milvus/MongoDB ;
- hypothèses de trafic et SLA ;
- benchmark de vision et vérité terrain ;
- décision fournisseur LLM/embeddings ;
- politique RGPD et sécurité de l'organisation.

5. Limites documentaires

Les références de prix et quotas sont datées du jour de consultation. L'étude n'a pas accès à des contrats commerciaux privés, à l'énoncé officiel non fourni ni à des mesures d'exécution d'un dépôt complet. Les chiffres restent des estimations à recalculer après cadrage.